

PROJET

ANALYSE COMPORTEMENTALE

CLIENTÈLE EN E-COMMERCE

Elaboré par :
Dhia Rouag

Supervisé par :
Mme
Fadoua Drira

PLAN DU PROJET




1.INTRODUCTION

2.ETAT DE L'ART

3.MÉTHODE
PROPOSÉ

4.ÉTUDE
EXPÉRIMENTALE

5.CONCLUSION ET
PERSPECTIVE




INTRODUCTION




INTRODUCTION

- 1) Contexte
- 2) Problématique
- 3) Objectif



CONTEXTE



analyse de 4 372 clients à travers
52 variables transactionnelles

E-commerce de cadeaux : analyse de 4 372 clients à travers 52 variables transactionnelles, comportementales et complémentaires. Les données sont volontairement imparfaites afin d'appliquer l'ensemble du processus Machine Learning

INTRODUCTION

ETAT DE L'ART

MÉTHODE
PROPOSÉ

ETUDE
EXPÉRIMENTALE

CONCLUSION ET
PERSPECTIVES

PROBLEMATIQUE



- *Comment exploiter les données clients pour identifier les profils à risque, prédire le churn et estimer la valeur client afin d'améliorer les décisions marketing ?*

INTRODUCTION

ETAT DE L'ART

MÉTHODE
PROPOSÉ

ETUDE
EXPÉRIMENTALE

CONCLUSION ET
PERSPECTIVES

OBJECTIFS



Segmenter la clientèle :

- **Identifier des groupes de clients aux comportements similaires.**

Prédire le churn :



- **Repérer les clients susceptibles de quitter la plateforme.**

Estimer la valeur client :

- **Prédire la dépense totale afin d'optimiser les actions marketing.**

Enjeu métier :

- **Mieux comprendre les clients pour fidéliser, cibler les offres et améliorer la rentabilité.**



ETAT DE L'ART

ETAT DE L'ART

- Apprentissage non supervisé
- Apprentissage supervisé



APPRENTISSAGE NON SUPERVISÉ

- L'apprentissage non supervisé est utilisé lorsque les données ne possèdent pas de variable cible connue.
- Son objectif est de découvrir automatiquement des structures ou des groupes dans les données.

APPRENTISSAGE NON SUPERVISÉ

K-means clustering :

- regroupe les clients en plusieurs segments selon leur similarité comportementale.

Avantages : Simple, rapide, scalable, interprétable.

Limite : Dépendance au nombre de clusters k

APPRENTISSAGE NON SUPERVISÉ

DBSCAN

- regroupe les clients selon leur densité et permet aussi de détecter les clients atypiques.

Avantages : détecte automatiquement des clusters de forme complexe et identifie les outliers.

Limite : dépend fortement du choix de `eps` et `min_samples`, et peut classer beaucoup de points comme bruit.

APPRENTISSAGE NON SUPERVISÉ

Méthodes pour choisir le nombre optimal de clusters :

Méthode Elbow :

- Analyse la diminution de l'inertie pour repérer le point où l'amélioration devient faible.

Score Silhouette :

- Mesure si les clusters sont bien séparés et cohérents. Plus le score est élevé, mieux c'est.

Score Davies-Bouldin :

- Évalue la compacité et la séparation des clusters. Plus le score est faible, mieux c'est.

APPRENTISSAGE SUPERVISÉ

- L'apprentissage supervisé est utilisé lorsque les données possèdent une variable cible connue.
- Le modèle apprend à partir d'exemples déjà étiquetés afin de prédire une sortie.

APPRENTISSAGE SUPERVISÉ : RÉGRESSION



Critère	Linear Regression	Random Forest Regressor
Utilisation	Prédire une valeur numérique avec une relation linéaire	Prédire une valeur numérique avec des relations complexes
Avantages principaux	Simple, rapide, facile à interpréter	Capte les relations non linéaires, performant sur données complexes
Limites principales	Limité si les relations ne sont pas linéaires	Moins interprétable, peut être plus coûteux en calcul

APPRENTISSAGE SUPERVISÉ : CLASSIFICATION




Critère	Logistic Regression	Random Forest	XGBoost
Utilisation	Prédiction binaire simple	Classification robuste	Classification avancée
Avantages principaux	Simple, rapide, interprétable	Gère bien les données mixtes, résiste au surapprentissage	Très performant, bonne capacité de généralisation
Limites principales	Moins efficace pour relations complexes	Peut être lourd avec beaucoup d'arbres	Plus complexe à paramétrer

MÉTHODE PROPOSÉ



MÉTHODE PROPOSÉ



- **Exploration des données**
- **Prétraitement & nettoyage**
- **Modèles proposés pour Clustering, classification et régression**
- **Évaluation & interprétation métier**

EXPLORATION DES DONNÉES



Une exploration des données a été réalisée afin de comprendre le dataset brut, détecter les valeurs manquantes, les anomalies, les outliers et les corrélations entre variables. Cette étape a aussi permis d'analyser la distribution de Churn et de guider les choix de preprocessing.

PRÉTRAITEMENT & NETTOYAGE



**THE DATA HAS BEEN
CLEANED AND PREPARED**

Les données ont été nettoyées et préparées avant la modélisation : traitement des valeurs manquantes et aberrantes, transformation des dates et adresses IP, suppression des colonnes inutiles ou à risque, puis normalisation des variables numériques et encodage des variables catégorielles.

MODÈLES PROPOSÉS

Clustering

Segmentation des clients selon leurs comportements.

Modèles : K-Means, DBSCAN.

Classification


Prédiction du churn client.

Modèles : Logistic Regression, Random Forest, XGBoost.

Régression

Estimation de la dépense totale du client.


Modèles : Linear Regression, Random Forest Regressor.



ÉVALUATION & INTERPRÉTATION MÉTIER



Silhouette



Accuracy / F1-score
ROC-AUC



MAE / RMSE
 R^2




INTRODUCTION

ETAT DE L'ART

MÉTHODE
PROPOSÉ

ETUDE
EXPÉRIMENTALE

CONCLUSION ET
PERSPECTIVES



ÉTUDE EXPÉRIMENTALE



ETUDE EXPERIMENTALE


- jeu de données
- Evaluation de la performance
- Comparaison avec d'autre modèle



DESCRIPTION DES DONNÉES

Aperçu général

- 4 372 clients analysés
- 52 variables initiales
- Cible principale : Churn (0 = client fidèle, 1 = client parti)



analyse de 4 372 clients à travers
52 variables transactionnelles

INTRODUCTION

ETAT DE L'ART

MÉTHODE
PROPOSÉ

ETUDE
EXPÉRIMENTALE

CONCLUSION ET
PERSPECTIVES

CATÉGORIES DE FEATURES

Categorie	Exemples
Transactionnelles / RFM	Recency, Frequency, MonetaryTotal
Comportementales	PreferredMoirth, WeekendPurchas Ratio, UniqueProducts
Qualité & service	ReturnRatio, SupportTicketsCount, SatisfactionScore
Catégorielles	Region, Country, Gender, Customer
Données brutes	RegistrationDate, LastLoginiP



EXPLORATION

L'exploration a permis d'identifier les principaux problèmes de qualité avant le preprocessing :


- Valeurs manquantes : principalement dans Age
- Valeurs aberrantes : SupportTicketsCount, SatisfactionScore
- Formats inconsistants : RegistrationDate
- Colonne constante : NewsletterSubscribed
- Corrélations fortes entre certaines variables numériques
- Déséquilibre modéré de la cible Churn

DISTRIBUTION DU CHURN

Distribution de la variable cible Churn



MATRICE DE CORRÉLATION



PRÉTRAITEMENT & NETTOYAGE

Problème	Exemple	Traitement appliqué
Valeurs manquantes	Age	Imputation par la médiane
Valeurs aberrantes	SupportTicketsCount, SatisfactionScore	Remplacement en NaN, puis imputation
Dates inconsistantes	RegistrationDate	Parsing + extraction année / mois / jour
Feature inutile	CustomerID	Suppression
Feature constante	NewsletterSubscribed	Suppression
Donnée brute	LastLoginIP	Extraction de IP_IsPrivate / IP_FirstOctet
Data leakage	ChurnRiskCategory, RFMSegment, CustomerType, LoyaltyLevel, SpendingCategory, AccountStatus	Suppression
Déséquilibre des classes	Churn	Split stratifié + pondération des classes

PRÉTRAITEMENT & NETTOYAGE

Problème	Exemple	Traitement appliqué
Donnée brute	LastLoginIP	Extraction de IP_IsPrivate, IP_FirstOctet
Catégorielles	Region, Country, Gender	OneHotEncoder
Numériques	Frequency, Age, etc.	StandardScaler
Multicolinéarité	Frequency ↔ UniqueInvoices	Analyse de redondance ; suppression uniquement des variables jugées inutiles ou à risque

PRÉTRAITEMENT & NETTOYAGE



- Lors de la première expérimentation, les modèles ont obtenu des scores presque parfaits, ce qui a révélé un risque de data leakage. Certaines variables comme **ChurnRiskCategory, RFMSegment, CustomerType, LoyaltyLevel** etc ...donnaient une information trop proche de Churn. Elles ont donc **été supprimées** afin d'éviter que le modèle "triche" et pour obtenir des résultats plus réalistes.

PRÉTRAITEMENT & NETTOYAGE



- La cible Churn présente un déséquilibre modéré : environ 66,7 % non-churn contre 33,3 % churn. Pour le traiter, un split stratifié a été utilisé afin de garder la même répartition dans train/test, puis une pondération des classes a été appliquée pendant l'entraînement (`class_weight="balanced"` et `scale_pos_weight`)

PRÉTRAITEMENT & NETTOYAGE

- Le feature engineering a été utilisé pour enrichir les données initiales en créant de nouvelles variables plus informatives. À partir des colonnes existantes, des indicateurs comme **AvgBasketValue**, **FrequencyIntensity**, **IP_IsPrivate**, **IP_FirstOctet** et les variables issues de **RegistrationDate** ont été générés afin d'améliorer la représentation du comportement client avant la modélisation.

CLUSTERING K-MEANS

- **Données utilisées :**


- **Dataset nettoyé : 4 372 clients × 48 colonnes**
- **Features utilisées pour le clustering : 38 variables numériques**
- **Données normalisées avant clustering**

- **Choix du meilleur k :**

- **Elbow : Pour observer la diminution de l'inertie**
- **Silhouette : Pour mesurer la séparation des clusters**
- **Davies-Bouldin : Pour vérifier la compacité des groupes**

CLUSTERING K-MEANS

K-Means — Sélection du k optimal



CLUSTERING K-MEANS


Résultats K-Means

Élément	Valeur
k optimal	2
Inertie	152038.02
Silhouette	0.8222
Davies-Bouldin	0.9948

Segments obtenus

Cluster	Effectif	Proportion	Profil
Cluster 0	4 355	99,6 %	Clients standards
Cluster 1	17	0,4 %	Clients VIP très actifs

CLUSTERING K-MEANS



CLUSTERING : DBSCAN

Paramètres utilisés

Paramètre	Valeur
eps	3.0
min_samples	5


Résultats obtenus

Élément	Résultat
Clusters détectés	5
Clients atypiques / outliers	733 clients
Pourcentage d'outliers	16,8 %
Score Silhouette	0,1687

CLUSTERING : DBSCAN

Segments importants			
Cluster	Effectif	Taux de churn	Interprétation
-1	733	26,33 %	Clients atypiques
0	3 617	34,50 %	Groupe principal
1	6	66,67 %	Micro-segment à risque
2	7	100 %	Segment critique
3	4	0 %	Micro-segment stable
4	5	40 %	Peitt groupe à surveiller

CLUSTERING : DBSCAN



LOGISTIC REGRESSION

La Logistic Regression a été configurée avec `max_iter=1000` pour assurer la convergence, `class_weight="balanced"` pour prendre en compte le déséquilibre des classes, et `random_state=42` pour garantir la reproductibilité des résultats.

LOGISTIC REGRESSION

- **513 non-churn bien prédits**
- **266 churn bien prédits**
- **71 faux positifs**
- **25 faux négatifs**

Matrice de confusion — LogisticRegression

True label	Non-Churn	Churn	
	513	71	
Non-Churn			
Churn	25	266	
Predicted label			
		Non-Churn	Churn

LOGISTIC REGRESSION

Résultats obtenus	
Métrique	Valeur
Accuracy	0.8903
Precision	0.7893
Recall	0.9141
F1-score	0.8471
ROC-AUC	0,9592

RANDOM FOREST

Le Random Forest Classifier a été configuré avec `n_estimators=300` pour construire un ensemble robuste d'arbres de décision, `class_weight="balanced"` pour prendre en compte le déséquilibre des classes, et `random_state=42` pour garantir la reproductibilité des résultats.

RANDOM FOREST

- **565 non-churn bien prédits**
- **237 churn bien prédits**
- **54 faux positifs**
- **19 faux négatifs**

Matrice de confusion — RandomForestClassifier

True label	Non-Churn	Churn	
	565	19	
Non-Churn	565	19	
Churn	54	237	
Predicted label			
		Non-Churn	Churn

RANDOM FOREST

Résultats obtenus	
Métrique	Valeur
Accuracy	0.9166
Precision	0.9258
Recall	0.8144
F1-score	0.8665
ROC-AUC	0.9743

XGBOOST


Le XGBoost Classifier a été configuré avec 300 arbres, une profondeur maximale de 6 et un taux d'apprentissage de 0.1. Les paramètres subsample=0.8 et colsample_bytree=0.8 permettent de réduire le surapprentissage, tandis que scale_pos_weight ≈ 2.007 prend en compte le déséquilibre entre les classes Churn et Non-Churn.

XGBOOST

Paramètres utilisés		
Paramètre	Valeur	Rôle
n_estimators	300	Nombre d'arbres construits
max_depth	6	Profondeur maximale de chaque arbre
learning_rate	0.1	Vitesse d'apprentissage du modèle
subsample	0.8	Utilise 80 % des lignes à chaque étape
colsample_bytree	0.8	Utilise 80 % des colonnes pour chaque arbre
scale_pos_weight	≈ 2.007	Gère le déséquilibre des classes
eval_metric	logloss	Métrique interne d'évaluation
random_state	42	Rend les résultats reproductibles
n_jobs	-1	Utilise tous les cœurs disponibles

XGBOOST




- **576 non-churn bien prédits**
- **273 churn bien prédits**
- **18 faux positifs**
- **8 faux négatifs**



XGBOOST

Résultats obtenus	
Métrique	Valeur
Accuracy	0.9703
Precision	0.9715
Recall	0.9381
F1-score	0.9545
ROC-AUC	0.9952

COMPARAISON




- LA COMPARAISON ROC MONTRE QUE XGBOOST EST LE MODÈLE LE PLUS PERFORMANT AVEC UN ROC-AUC = 0.9952, SUIVI DE RANDOM FOREST PUIS LOGISTIC REGRESSION. CELA INDIQUE QUE XGBOOST DISTINGUE LE MIEUX LES CLIENTS CHURNERS DES NON-CHURNERS.

LINEAR REGRESSION

La Linear Regression a été utilisée comme modèle de référence pour prédire MonetaryTotal. Ce modèle ne nécessite pas d'hyperparamètres spécifiques dans notre implémentation ; il sert principalement de baseline afin de comparer ses performances avec un modèle plus avancé.

LINEAR REGRESSION

Évaluation de la régression — LinearRegression



INTRODUCTION

ETAT DE L'ART

MÉTHODE
PROPOSÉ

ETUDE
EXPÉRIMENTALE

CONCLUSION ET
PERSPECTIVES

LINEAR REGRESSION

Résultats Obtenus	
Métrique	Valeur
MAE	829.18 £
RMSE	3068.63 £
R^2	0.8422

RANDOM FOREST REGRESSOR

Le Random Forest Regressor a été configuré avec **n_estimators=200** pour construire un ensemble de 200 arbres, **max_depth=15** pour limiter la profondeur des arbres et réduire le surapprentissage, **random_state=42** pour garantir la reproductibilité, et **n_jobs=-1** pour utiliser tous les cœurs disponibles lors de l'entraînement.

RANDOM FOREST REGRESSOR


Évaluation de la régression — RandomForestRegressor




RANDOM FOREST REGRESSOR

Résultats Obtenus	
Métrique	Valeur
MAE	586.46 £
RMSE	2272.96 £
R ²	0.9134

RANDOM FOREST REGRESSOR OBTIENT L'ERREUR MOYENNE LA PLUS FAIBLE ET LE MEILLEUR R². IL EXPLIQUE ENVIRON 91.3 % DE LA VARIATION DE MONETARYTOTAL.



DEPLOIEMENT



 **RetailML**

3 modèles actifs

Classification – Churn

Régression – Dépense

Clustering – Segment

Tout en un

Prédiction Churn Client

// Classification – Random Forest – Le client va-t-il partir ?

PREDICTIONS

0

cette session

CHURNS DÉTECTÉS

0

clients à risque

CLIENTS FIDÈLES

0

non-churn

TAUX DE CHURN

0%

% session

Données client

// Features: RFM + comportementales

FREQUENCY (CMD)

5

MONETARYTOTAL (€)

350

AGE

35

SATISFACTION (1-5)

3

SUPPORT TICKETS

1

CUSTOMER TENURE (J)

180

En attente d'une prédiction...

Probabilité de Churn

0% Fidele


50% Seuil

100% Churn

Activer Windows


Accédez aux paramètres pour activer Windows.

60



CONCLUSION ET PERSPECTIVE

CONCLUSION




- Mise en place d'une chaîne complète de Machine Learning.
- Nettoyage, preprocessing, clustering, classification et régression.
- XGBoost retenu pour la prédiction du churn.
- Random Forest Regressor retenu pour la prédiction de la dépense client.
- Résultats exploitables pour la segmentation, la fidélisation et l'aide à la décision.

PERSPECTIVES

- Optimisation des hyperparamètres.
- Test d'autres méthodes de rééquilibrage comme SMOTE.
- Ajout de données réelles plus riches.
- Ajout de recommandations marketing personnalisées.





**MERCI POUR VOTRE
ATTENTION**

